Model Card — Agente de Monitoramento de Risco de Evasão

ASA Turbo · FECAP · Versão 2.0.0

> Todos os números deste Model Card são extraídos de `ml/artifacts/resultados_e2.json`.

Detalhes do Modelo

Campo	Valor
Nome	Agente de Monitoramento de Risco de Evasão
Versão	`risco-2.0.0`
Tipo	XGBoost com restrições monotônicas + calibração isotônica
Tarefa	Classificação binária (evadiu / não evadiu) com score probabilístico
Treinado em	2026-11-02T21:42:42+00:00
SHA256 do artefato	`c98263417baaec72e18a01e23b6e8c17b5134785e2bb4c68bc0fb291dc7ed66e`
Artefato	`ml/artifacts/risco_v2.joblib`
Versionamento	`ml/artifacts/MODEL_VERSION.json`
Linguagem	Python 3.12 · scikit-learn 1.9 · XGBoost 3.4 · joblib 1.6

Uso Pretendido

Para quem: atendentes do ASA da FECAP, para priorizar quais estudantes contatar preventivamente.

Como usar:

- O atendente acessa a fila de risco na tela do aplicativo.
- Cada linha mostra score, categoria (Verde/Amarelo/Vermelho), fatores e recomendação.
- O atendente valida, ajusta ou rejeita a sugestão com justificativa escrita.
- Toda ação fica no histórico de auditoria.

O estudante nunca vê o score nem os fatores.

Uso Fora do Escopo

Uso proibido	Motivo

Cancelar vínculo, bloquear acesso ou aplicar penalidade automaticamente	Regra inegociável do projeto
Usar score como único critério de decisão	O modelo apoia, não decide
Exibir score ou fatores ao estudante	Privacidade; o estudante pode interpretar como penalização
Usar para fins diferentes de apoio ao ASA da FECAP	Fora do escopo de treinamento
Usar em contexto com distribuição muito diferente do treino	A base é histórica (pós-desfecho)
Usar para discriminar por sexo, estado civil ou idade	Esses atributos foram removidos

---

Dados

Fonte

- Base histórica de matrículas da FECAP fornecida pelo ASA.
- **Dados reais não estão no repositório** (`.gitignore`). No repositório existem apenas métricas e figuras agregadas.
- **O período de referência do rótulo** `evadiu` **não foi confirmado formalmente com o ASA.** Esta é uma limitação reconhecida.

Divisão

Conjunto	N	% Evasão
Treino (75 %)	9.626	19,56 %
Teste (25 %)	3.209	19,57 %

Pré-processamento

- 7 duplicatas removidas; 2 notas > 100 corrigidas.
- 32 registros com atraso atípico sinalizados (recebem "dados insuficientes" na inferência).
- Split estratificado pelo rótulo, semente 42.

Features utilizadas (19)

`tempo_de_curso` , `Idade` , `mora_sp_capital` , `total_parcelas` , `pct_parcelas_em_aberto` , `pct_parcelas_acordo` , `atraso_medio_dias` , `valor_total_periodo` , `media_notas` , `media_assiduidade` , `pct_reprovacao` , `tendencia_notas` , `tendencia_assiduidade` , `total_semestres` , `tem_bolsa` , `sem_historico_academico` , `Forma de Ingresso` , `Grau Acadêmico` , `Turno`

Features removidas

Feature	Motivo

`Sexo`	Atributo sensível; perda de AUC < 0,01
`Estado Civil`	Atributo sensível; perda de AUC < 0,01
`total_contatos`	Regra 5: contatos do ASA não podem aumentar o score
`dias_desde_ultimo_contato`	Mesmo motivo

Avaliação

Desempenho no teste (XGBoost monotônico calibrado)

Limiar	AUC-ROC	PR-AUC	Recall	Precisão	F1	Brier
0,10 (recomendado)	0,9129	0,7550	**0,8869**	0,4528	0,5996	0,0830
0,30 (contrato)	0,9129	0,7550	0,7580	**0,6355**	**0,6914**	0,0830

Comparação com baseline (Entrega 1)

Métrica	Baseline RL (E1)	v2 XGBoost (E2)
AUC	0,82	**0,91**
Recall (limiar 0,30)	77,1 %	75,8 %
Precisão (limiar 0,30)	41,8 %	**63,6 %**

Calibração das faixas (configuração recomendada ≥ 0,10 / ≥ 0,60)

Faixa	% Alunos	Taxa real de evasão
Verde (< 0,10)	61,7 %	**3,6 %**
Amarelo (0,10–0,60)	24,5 %	**24,7 %**
Vermelho (≥ 0,60)	13,8 %	**81,9 %**

As faixas são monotônicas: a taxa real de evasão aumenta conforme o score.

Equidade

Grupo	Gap de Recall	Gap FPR
Turno	0,1403	0,1476
Forma de Ingresso	0,1682	**0,4099**
Grau Acadêmico	0,0877	0,1247

Faixa etária	0,0908	0,1833
Sexo	**0,0317**	0,1069

A maior disparidade está em **Forma de Ingresso**: grupos com menos histórico têm mais falsos positivos. Recomendação: protocolo de acolhimento para ingressantes sem histórico antes da implantação plena.

Variante treinada sem `Sexo` e `Estado Civil` apresenta AUC-CV dentro de 0,01 do modelo completo; os gaps de equidade não pioram. O modelo final **não usa esses atributos**.

Considerações Éticas

- **Nenhuma decisão automática.** O sistema é de apoio à decisão. Toda ação com impacto no vínculo do estudante exige validação humana registrada com justificativa escrita.
- **O estudante nunca vê o score.** A exibição do score poderia ser interpretada como penalização ou estigmatização.
- **Abstenção documentada.** Registros com dados insuficientes recebem "revisar manualmente" em vez de um score, evitando falsa precisão.
- **Auditoria completa.** Todo score gerado registra: usuário, data/hora, versão do modelo, features usadas (sem dados pessoais brutos), resultado e decisão humana.
- **LGPD:** nenhum dado pessoal real é versionado. Credenciais estão fora do Git. Features sensíveis (Sexo, Estado Civil, Idade) não são exibidas como fatores.
- **Regra 5:** contatos legítimos do estudante com o ASA nunca aumentam o score (feature removida).
- **Uso restrito:** o modelo foi treinado na realidade da FECAP. Aplicar em outra instituição sem re-treinamento é inadequado.

Limitações

- **Rótulo não confirmado:** o período de referência do campo `evadiu` não foi formalmente confirmado com o ASA. Isso pode inflar as métricas.
- **Dados pós-desfecho:** a AUC de 0,91 no teste tende a cair com dados de corte reais (antes do desfecho). A v3 deve usar features com data de corte anterior à evasão.
- **Distribuição histórica:** o modelo captura padrões históricos que podem não refletir o comportamento futuro (mudanças em políticas de bolsas, pandemia, etc.).
- **Ausência de feedback real:** a precisão do modelo nunca foi validada com um ciclo real de contatos e resultados. Monitorar taxa de resposta (aluno reconectou? continuou?) é essencial para a v3.
- **Pós-Graduação e Tecnólogo:** recall ligeiramente menor que Bacharelado; recomendar protocolo específico para esses graus.

Histórico de Versões

v1.0 (Entrega 1 — 2026-10)

- **Algoritmo:** Regressão Logística com `class_weight=balanced`
- **AUC:** 0,82 | **Recall:** 77,1 % | **Precisão:** 41,8 % (limiar 0,30)
- **Features:** 15 (incluindo `total_contatos` e `dias_desde_ultimo_contato`)
- **Sem calibração de probabilidade**
- **Sem análise de equidade nem SHAP**
- **Faixas:** Verde < 30 %, Amarelo 30–60 %, Vermelho ≥ 60 % (sem calibração)

v2.0.0 (Entrega 2 — 2026-11-02)

- **Algoritmo:** XGBoost com restrições monotônicas + calibração isotônica
- **AUC:** 0,91 | **Recall:** 88,7 % (limiar 0,10) | **Precisão:** 63,6 % (limiar 0,30)
- **Features:** 19 (Sexo e Estado Civil removidos; total_contatos e dias_desde_ultimo_contato removidos)
- **Calibração:** isotonic regression — Brier 0,083
- **Equidade:** análise por turno, forma de ingresso, grau acadêmico, faixa etária e sexo
- **Explicabilidade:** TreeSHAP nativo — 6 fatores por aluno com direção e peso
- **Abstenção:** registros com dados insuficientes recebem categoria `dados_insuficientes`
- **Versionamento:** MODEL_VERSION.json com SHA256, features, limiares e justificativa
- **Integração:** modelo final carregado pelo backend via `ml/artifacts/risco_v2.joblib`

Gerado em 06/11/2026 · ASA Turbo v0.9 · FECAP Projeto Interdisciplinar 5º CCOMP 2026.2