Relatório de Resultados — Entrega 2 (IA)

ASA Turbo · Projeto Interdisciplinar FECAP · 5º CCOMP · 2026.2

Gerado em: 06/11/2026 | Versão do modelo: risco-2.0.0 | Versão do relatório: 2.0.0

> Todos os números deste relatório são extraídos de `ml/artifacts/resultados_e2.json`, gerado por `ml/consolidar_resultados.py` a partir de `ml/artifacts/metrics.json` e `ml/artifacts/rag_metrics.json`. Nenhum número foi digitado à mão.

1. Objetivo

O projeto desenvolve dois agentes de IA para o ASA (Área do Sucesso Alvarista) da FECAP:

- **Agente de Monitoramento** — classifica o risco de evasão de cada aluno em Verde / Amarelo / Vermelho, listando os fatores contribuintes para o atendente priorizar contatos. Nunca gera decisão automática; toda ação com impacto exige validação humana registrada.
- **Agente para o Estudante (ASA Turbo)** — chatbot RAG (Recuperação Aumentada por Geração) que responde dúvidas usando exclusivamente documentos oficiais da FECAP. Abstém-se quando a pergunta está fora do escopo ou a similaridade está abaixo do limiar; nunca inventa procedimento, prazo ou regra.

2. Dados e Preparação

Etapa	Valor
Registros brutos	12.842
Duplicatas removidas	7
Notas acima de 100 corrigidas	2
Registros com atraso outlier (>365 dias) sinalizados	32
Registros finais	**12.835**
Treino (75 %)	9.626
Teste (25 %)	3.209
Taxa de evasão no treino	19,56 %
Taxa de evasão no teste	19,57 %
Semente	42

A divisão é estratificada pelo rótulo `evadiu` para garantir proporções iguais de evasão em treino e teste. O mesmo split é usado em todos os modelos para comparação justa.

Nota sobre o rótulo: o campo `evadiu` foi definido pela equipe com base nos dados históricos do ASA. O período de referência exato (quando um aluno é considerado evadido) **não foi confirmado formalmente com o ASA**; isso é uma limitação do projeto.

---

3. Modelos Comparados e Validação

Validação cruzada estratificada (5 folds, no treino — sem usar o teste)

Modelo	AUC-ROC	PR-AUC	Recall	Precisão	F1	Brier
Regressão Logística (baseline)	0,8347	0,5988	0,7939	0,4196	0,5490	0,1673
Random Forest	0,9383	0,8611	0,6474	0,9021	0,7535	0,0648
XGBoost monotônico	**0,9346**	**0,8548**	**0,7701**	**0,8521**	**0,7676**	**0,0729**

Comparação no conjunto de teste (calibrado, limiar = 0,5)

Modelo	AUC-ROC	PR-AUC	Recall	Precisão	F1	Brier
Regressão Logística	0,8347	—	—	—	—	—
Random Forest	0,9383	—	—	—	—	—
XGBoost (sem monotonia)	0,9346	—	—	—	—	—
XGBoost monotônico (escolhido)	**0,9129**	**0,7550**	**0,7580**	**0,6355**	**0,6914**	**0,0830**

Justificativa da escolha: XGBoost monotônico

- RF e XGBoost empatam na CV por AUC (diferença < 0,005). Fica o XGBoost, que oferece TreeSHAP nativo (explicação exata por aluno) e artefato menor.
- As restrições monotônicas custam 0,014 de AUC na CV (0,929 → 0,915), mas impedem artefatos do retrato pós-desfecho (ex.: 0% de parcelas em aberto associado a mais evasão). Aceitas porque a perda está abaixo do limite de 0,03.
- Sexo e Estado Civil foram removidos: perda de AUC < 0,01 e as lacunas de recall/FPR entre grupos não pioram.
- `total_contatos` e `dias_desde_ultimo_contato` foram removidos (Regra 5): a base não separa pedidos do estudante de contatos ativos do ASA.

---

4. Métricas e Limiares

Métricas no teste (XGBoost monotônico calibrado por isotonic regression)

Limiar	Recall	Precisão	F1	Brier	% Sinalizados
0,10 (recomendado)	**0,8869**	0,4528	0,5996	0,0830	38,3 %

0,30 (contrato atual)	0,7580	0,6355	0,6914	0,0830	23,3 %
0,60 (somente Vermelho)	0,5780	0,8194	0,6779	0,0830	13,8 %

Cobertura de atendimento (quantos alunos contatar para capturar X% dos que evadem)

Contatar	N alunos	Limiar equiv.	Recall	Precisão	Lift
5 %	161	0,8606	22,9 %	89,4 %	4,57×
10 %	321	0,7168	44,1 %	86,3 %	4,41×
15 %	482	0,5745	61,5 %	80,1 %	4,09×
20 %	643	0,4601	73,9 %	71,8 %	3,67×

Faixas de risco (calibração das probabilidades)

Configuração atual (limiar Amarelo ≥ 0,30 / Vermelho ≥ 0,60):

Faixa	% Alunos	Taxa real de evasão	Prob. média prevista
Verde (< 0,30)	76,7 %	6,2 %	5,8 %
Amarelo (0,30–0,60)	9,5 %	36,9 %	44,8 %
Vermelho (≥ 0,60)	13,8 %	81,9 %	79,7 %

Configuração recomendada (Amarelo ≥ 0,10 / Vermelho ≥ 0,60):

Faixa	% Alunos	Taxa real de evasão	Prob. média prevista
Verde (< 0,10)	61,7 %	3,6 %	3,0 %
Amarelo (0,10–0,60)	24,5 %	24,7 %	28,1 %
Vermelho (≥ 0,60)	13,8 %	81,9 %	79,7 %

A calibração por isotonic regression garante que a probabilidade prevista é compatível com a taxa real de evasão observada (Brier score 0,083 no teste).

Comparação com baseline da Entrega 1:

Métrica	Baseline E1 (RL, limiar 0,30)	v2 (XGBoost, limiar 0,30)	Melhoria
AUC	0,82	**0,91**	+11 pp
Recall	77,1 %	**75,8 %**	−1,3 pp (troca recall por precisão)
Precisão	41,8 %	**63,6 %**	+21,8 pp
% Sinalizados	36,1 %	**23,3 %**	−12,8 pp

5. Análise de Erros

Corte da análise: limiar recomendado 0,10.

Resultado	N
Verdadeiros Positivos (VP)	557
Falsos Negativos (FN) — evadiram sem ser sinalizados	71
Falsos Positivos (FP) — sinalizados sem evadir	673
Verdadeiros Negativos (VN)	1.908

Perfil dos Falsos Negativos (perdemos esses alunos)

- Nota mediana **65** (VN: 66), frequência mediana **91 %** (VN: 92 %), 3 semestres cursados.
- São alunos que, pelos dados disponíveis, pareciam estar indo bem. A evasão deles não tem sinal preditivo nos dados atuais.

Perfil dos Falsos Positivos (sinalizamos, mas não evadiram)

- 58 % não têm nota nem frequência registradas, tempo de curso mediano = 0 e valor do período mediano R$ 12.800 (VP: R$ 5.132).
- São principalmente ingressantes sem histórico. Um contato de acolhimento nesses casos tem baixo custo e não é perdido.

Observações práticas

- **Falsos negativos parecem alunos que ficam:** nota e frequência medianas próximas ao grupo VN. A evasão de quem estava bem não tem sinal disponível nos dados.
- **Falsos positivos são ingressantes sem histórico:** 58 % não têm notas nem frequência lançadas — o modelo sinaliza quem parece um típico evadente por falta de dados, não por desempenho ruim.
- **Pós-Graduação responde por 37 % dos FN.** Recall por grau: Bacharelado 87 %, Pós-Graduação 90 %, Tecnólogo 96 %. Vale protocolo próprio para Pós-Grad (ex.: contato no 1º mês).
- **Veteranos escapam mais:** os FN têm mediana de 35 parcelas contra 18 dos VP. Recalcular o score mensalmente com dados correntes é o caminho.
- **A base é um retrato pós-desfecho:** quem evadiu tem 0 parcelas em aberto (encerradas) e 69 % dos VP não têm notas lançadas. Isso infla a AUC. A v3 precisa de features com data de corte anterior à evasão.

6. Explicabilidade

A explicabilidade é feita por **contribuição de atributo por aluno**: para cada feature, calcula-se a diferença de logit entre a probabilidade com aquele valor e com o valor de referência (mediana/moda do grupo). Para o XGBoost o cálculo usa TreeSHAP nativo.

Importância global (média do |SHAP|, top 5)

Atributo	Contribuição média	Importância por permutação (ΔAUC)
valor_total_periodo	1,2224	0,2539
tempo_de_curso	0,4977	0,0536
total_parcelas	0,3983	0,0376
Idade	0,4075	0,0361
total_semestres	0,3493	0,0240

> **Nota:** `Idade` aparece com alta contribuição média mas **nunca é exibida como fator** na tela do atendente (atributo sensível, incluída apenas no modelo por correlação com tempo de curso).

Exemplo anônimo (perfil de alto risco)

- Perfil: ingressante, 1 semestre, valor do período R$ 5.200, 42 % das parcelas em aberto, nota 41, frequência 63 %, 40 % de reprovação.
- Score previsto: **91,2 %** (Vermelho).
- Fatores exibidos: valor do período abaixo da mediana (+), notas baixas (+), frequência baixa (+).

A API expõe o formato `{codigo, descricao, dimensao, direcao, peso}` para cada fator (máx. 6), com direção ("aumenta" / "reduz" o risco) e peso relativo entre os fatores mostrados.

---

7. Equidade

Análise realizada no limiar recomendado (0,10) sobre o conjunto de teste.

Lacunas de recall e taxa de falsos positivos por grupo

Grupo	Gap de Recall (max − min)	Gap FPR
Turno	0,1403	0,1476
Forma de Ingresso	0,1682	0,4099
Grau Acadêmico	0,0877	0,1247
Faixa etária	0,0908	0,1833
Sexo	**0,0317**	**0,1069**

A maior disparidade está em **Forma de Ingresso** (FPR gap = 0,41): modalidades com menos histórico acadêmico disponível (ex.: convênios, transferências recentes) têm mais FP porque o modelo sinaliza ingressantes sem dados. Isso recomenda um protocolo de acolhimento diferenciado, não penalização.

Variante sem Sexo e Estado Civil: perda de AUC-CV < 0,01; os gaps de recall/FPR por grupo não pioram. O modelo final **não usa Sexo nem Estado Civil** como features.

Recomendação

Monitorar mensalmente o recall por Forma de Ingresso; estabelecer meta de recall ≥ 80 % para todos os grupos antes da implantação plena.

---

8. Avaliação do Agente para o Estudante (RAG)

Corpus de avaliação

- 20 documentos fictícios (Entrega 1, seed_v2.sql).
- 60 perguntas: 20 diretas, 20 reformuladas, 8 de continuação, 6 fora do escopo próximas, 6 fora do escopo distantes.

> **Limitação:** os documentos são fictícios. O comportamento com a base real (230 documentos do ASA) precisará ser reavaliado.

Comparação de métodos (dentro do escopo, N=48)

Método	Recall@1	Recall@3	MRR	Acerto Agente	Abs. Correta	Abs. Indevida	CV
TF-IDF hashing	0,7292	0,9375	0,8333	0,6333	58,3 %	14,6 %	0,5833
TF-IDF + tabela IDF	0,7292	0,9167	0,8365	0,6833	83,3 %	22,9 %	0,6333
MiniLM-L6	0,5208	0,6875	0,6249	0,5333	58,3 %	20,8 %	0,5333
MiniLM-L12 multilíngue	0,7083	0,8542	0,8002	0,7000	66,7 %	8,3 %	0,6500
bge-m3 (produção)	**0,9375**	**0,9583**	**0,9509**	**0,9000**	**100 %**	**10,4 %**	**0,8667**

Método escolhido: bge-m3 · limiar 0,5511

- Acerto do agente 90 % (CV: 86,7 %).
- Abstém corretamente em **100 %** das perguntas fora do escopo (limiar 0,5511).
- Groundedness: 100 % das respostas são fundamentadas nos trechos recuperados (resposta extrativa — risco de responder com o documento errado: 1 caso em 43 avaliados).

Abstenção e erros

- **Abstém corretamente:** todas as 12 perguntas fora do escopo são encaminhadas para humano.
- **Abstém indevidamente:** 10,4 % das perguntas dentro do escopo (5/48) ficam sem resposta — principalmente perguntas de continuação sem contexto.
- **Resposta errada:** 1 caso (documento recuperado correto mas resposta não responde à pergunta).
- **Erros de continuação sem contexto:** sem a última pergunta do usuário concatenada, o Recall@1 de continuação cai de 100 % para 62,5 %.

---

9. Abstenção

Agente de Monitoramento

Registros com **dados insuficientes** (atraso_medio_dias outlier > 365 dias, ou ausência de todos os campos financeiros) recebem `categoria = "dados_insuficientes"` e recomendação de **revisão manual**, sem score numérico. No conjunto de limpeza foram detectados **32 registros** com atraso atípico.

Agente para o Estudante

O agente se abstém quando a similaridade do chunk mais próximo fica abaixo de **0,5511** (bge-m3). Neste caso, responde:

> "Não encontrei isso nos documentos oficiais. Quer que eu encaminhe para o ASA?"

---

10. Versionamento

Modelo de risco

- Versão: `risco-2.0.0`
- Treinado em: 2026-11-02T21:42:42+00:00
- SHA256 do artefato: `c98263417baaec72e18a01e23b6e8c17b5134785e2bb4c68bc0fb291dc7ed66e`
- Limiares ativos: Amarelo ≥ 0,30 / Vermelho ≥ 0,60
- Limiares recomendados: Amarelo ≥ 0,10 / Vermelho ≥ 0,60
- Exposto pelo backend em `GET /risco/modelo` (campo `versao`).
- Todo score retornado pela API inclui `versao_modelo` e `calculado_em`.

Base de conhecimento (RAG)

- Versão por documento: registrada na tabela `documentos` (campo `versao_conteudo`).
- Hash do conjunto: exposto em `GET /health` (campo `versao_modelo_risco` para o modelo; versão da base de conhecimento exposta na auditoria de cada resposta do chat, campo `versao_base`).
- Toda resposta do chat registra `versao_base` e `fonte` na auditoria.

---

11. Arquitetura e Endpoint de Inferência

Endpoint de risco integrado ao aplicativo

- **Rota:** `POST /risco/inferir`
- **Autenticação:** JWT Supabase com papel `administrador` ou `equipe_tecnica`
- **Entrada:** `estudante_id` (busca features do banco) ou `features` (simulação)
- **Saída:** `probabilidade`, `categoria`, `score` (geral/financeiro/acadêmico/relacionamento), `fatores` (código, descrição, dimensão, direção, peso), `recomendacao`, `versao_modelo`, `calculado_em`, `persistido`, `score_id`

- **Modelo carregado:** `ml/artifacts/risco_v2.joblib` (XGBoost monotônico calibrado, versão `risco-2.0.0`). Fallback para placeholder RL se o artefato não for encontrado.

Fluxo confirmado

Tela do atendente → fila de risco (seeds + scores do modelo real) → clica no aluno → detalhe com score, fatores, tendência, recomendação e versão do modelo → validação humana com justificativa → auditoria gravada.

A integração usa `ModeloML` que envolve `RiskModel` da sessão de ML (TreeSHAP nativo), com suporte a `ModeloSklearn` para o formato legado.

---

12. Limitações e Uso Adequado

- **Rótulo não confirmado:** o campo `evadiu` foi definido com base nos dados do ASA, mas o período de referência exato não foi confirmado formalmente. Isso pode inflar a AUC.
- **Dados pós-desfecho:** a base é um retrato tirado após o desfecho; a AUC tende a cair com dados de corte reais. A v3 precisa de features com data anterior à evasão.
- **Documentos fictícios:** o chatbot foi avaliado sobre documentos fictícios (Entrega 1). Com a base real (230 documentos), o comportamento precisará ser reavaliado.
- **Disparidade por Forma de Ingresso:** grupos com menos histórico têm mais falsos positivos. Monitorar continuamente.
- **Resposta extrativa:** o chatbot reproduz trechos dos documentos, o que é seguro (nunca inventa), mas pode resultar em respostas longas ou imprecisas para perguntas complexas.
- **Nenhuma decisão punitiva automática:** o sistema é de apoio. Toda ação com impacto no vínculo do aluno exige validação humana registrada com justificativa.
- **Score não é o único dado:** o atendente deve considerar o score em conjunto com o conhecimento do caso; estudantes com `dados_insuficientes` devem ser revisados manualmente.

---

13. Próximos Passos

- Confirmar com o ASA o período de referência do rótulo `evadiu` e criar feature com data de corte anterior ao desfecho.
- Substituir os documentos fictícios pelos documentos reais e reavaliar o RAG com as 60 perguntas (atualizar `perguntas.jsonl`).
- Ajustar o limiar Amarelo de 0,30 para 0,10 no contrato da API, após validação com o ASA sobre capacidade de atendimento.
- Implementar protocolo de acolhimento diferenciado para ingressantes sem histórico (principais FP).
- Monitorar mensalmente o recall por Forma de Ingresso e Grau Acadêmico.
- Treinar v3 com features de corte temporal e dados reais de alunos ativos (não retrospectivos).
- Recalcular embeddings com a base real e validar abstenção com perguntas reais dos estudantes.